


Mastering the game of Go without human knowledge

발표자: 박준영



AlphaGo Zero

: 인간의 지식 없이 랜덤에서 시작하여 바둑 최고의 경지까지 오른 인공지능.



인간의 지식 (Human Knowledge)?

| Feature | # of planes | Description |
|----------------------|-------------|---|
| Stone colour | 3 | Player stone / opponent stone / empty |
| Ones | 1 | A constant plane filled with 1 |
| Turns since | 8 | How many turns since a move was played |
| Liberties | 8 | Number of liberties (empty adjacent points) |
| Capture size | 8 | How many opponent stones would be captured |
| Self-atari size | 8 | How many of own stones would be captured |
| Liberties after move | 8 | Number of liberties after this move is played |
| Ladder capture | 1 | Whether a move at this point is a successful ladder capture |
| Ladder escape | 1 | Whether a move at this point is a successful ladder escape |
| Sensibleness | 1 | Whether a move is legal and does not fill its own eyes |
| Zeros | 1 | A constant plane filled with 0 |
| Player color | 1 | Whether current player is black |

Feature planes used by the policy network (all but last feature) and value network (all features).


인간의 지식 (Human Knowledge)?

| Feature | # of planes | Description |
|----------------------|-------------|---|
| Stone colour | 3 | Player stone / opponent stone / empty |
| Ones | 1 | A constant plane filled with 1 |
| Turns since | 8 | How many turns since a move was played |
| Liberties | 8 | Number of liberties (empty adjacent points) |
| Capture size | 8 | How many opponent stones would be captured |
| Self-atari size | 8 | How many of own stones would be captured |
| Liberties after move | 8 | Number of liberties after this move is played |
| Ladder capture | 1 | Whether a move at this point is a successful ladder capture |
| Ladder escape | 1 | Whether a move at this point is a successful ladder escape |
| Sensibleness | 1 | Whether a move is legal and does not fill its own eyes |
| Zeros | 1 | A constant plane filled with 0 |
| Player color | 1 | Whether current player is black |

Feature planes used by the policy network (all but last feature) and value network (all features).


AlphaGo Zero에 쓰인 domain knowledge


- 완벽한 게임 규칙(perfect knowledge of the game rules)
 - 각 상황마다 할 수 있는 선택지를 알려준다.
 - 722턴이 끝나면 게임 강제 종료.
- Tromp-Taylor scoring 방식으로 점수 산정
 - 사람이 주로 쓰는 규칙(한국를, 중국를, 일본를)은 완벽하지 않아 각종 예외가 존재.
 - 수학적으로 명확한 Tromp Taylor 규칙을 이용해 학습.
- 바둑판은 rotation이나 reflection에 대해 invariant
 - 위와 같은 변환을 이용해 학습 데이터 뻥튀기 가능.



학습데이터를 만드는 과정

Neural network training






서로가 서로를 보완하며 발전


인간의 직감에 해당하는 구조.

둘만한 곳은 어디?



지금 대충 얼마나 유리?

WHAT IS A 'GAME STATE'



<u>Dual</u> + <u>Residual</u>

Policy와 Value를 동시에 출력

Residual Network를 사용

Dual



Separate








Figure 2. Residual learning: a building block.

Residual Network

: 앞의 Residual Block을 많이 쌓은 신경망 모델






- Convolutional Block
 - 256 filters, 3×3 kernel convolution layer
 - Batch normalization
 - Rectifier nonlinearity

- Residual Block
 - 256 filters, 3×3 kernel convolution layer
 - Batch normalization
 - Rectifier nonlinearity
 - 256 filters, 3×3 kernel convolution layer
 - Batch normalization
 - Skip connection
 - Rectifier nonlinearity

- Policy Head
 - 2 filters, 1×1 kernel convolution layer
 - Batch normalization
 - Rectifier nonlinearity
 - Fully connected layer (output: \mathbb{R}^{19^2+1})

- Value Head
 - 1 filters, 1×1 kernel convolution layer
 - Batch normalization
 - Rectifier nonlinearity
 - Fully connected layer (output: \mathbb{R}^{256})
 - Rectifier nonlinearity
 - Fully connected layer (output: \mathbb{R}^1)
 - Tanh layer



Tree Node

- \circ 각 노드마다 상태 (s_t) , 행동 (a_t) 밑 통계치를 저장.
- *N*(*s*, *a*): 해당 노드에 방문한 횟수 (탐색한 횟수)
- ∘ *W*(*s*, *a*): 해당 value의 총합
- Q(s,a): 해당 노드의 승률
- ∘ *P*(*s*, *a*): 해당 노드의 policy

Select

- : 탐색할 노드를 찾기 위한 과정
 - PUCT 알고리즘을 사용.

$$u(s,a) = c_{\text{puct}} P(s,a) \frac{\sqrt{\sum_b N(s,b)}}{1 + N(s,a)}$$

- \circ c_{puct} : 트리 탐색의 깊이/너비를 조절하는 상수.
- 너무 한 노드만 탐색하는 것을 막기 위한 알고리즘.

Select

: 탐색할 노드를 찾기 위한 과정

• 최종적으로 다음의 수식에 따라 탐색할 노드를 선택.

$$a_t = \operatorname{argmax}_a(Q(s, a) + u(s, a))$$

• Leaf node에 도달할 때까지 반복.

Expand and Evaluate

: 선택된 노드를 탐색하고 이후 상태를 예측하는 과정.

- 탐색할 노드를 인공 신경망 연산 Task Queue에 넣고 대기.
- 인공 신경망에서 나온 policy 값을 이용해 다음 상태를 expand.

Backup

: 인공신경망에서 나온 값을 바탕으로 tree를 업데이트 하는 과정.

Leaf node에서 root node 방향으로 반대로 value를 업데이트 함.

→ 이 모든 과정(simulation)을 다수의 스레드에서 병렬적으로 수행.

Play

: 실질적으로 다음 행동을 결정하는 과정.

- 정해진 시간동안 또는 정해진 횟수만큼 simulation을 수행한 뒤 멈춤.
- Root node의 자식 노드 중에서 방문 횟수가 가장 많은 행동을 선택.
 - 많이 방문 = 좋은 행동

Training Pipeline

- 1. Selfplay
- 2. Optimization
- 3. Evaluation
 - → 위 세 과정은 병렬적으로 수행된다.

Training Pipeline - Selfplay

: 학습 데이터를 만드는 과정

- \circ 현재 최고의 모델 α_{θ} 를 이용해 학습 데이터를 생성.
- 한 iteration에 25,000 게임을 수행.
- 한 턴당 1,600회 MCTS 시뮬레이션 수행.
- MCTS simulation 결과와 게임의 결과를 바탕으로 학습 데이터 생성.
 - 30번째 턴까지는 $\tau = 1$ 을 사용, 이후로는 $\tau \to 0$ 을 사용. (시작 단계에서의 다양성을 보장하기 위해)

$$\pi \approx \frac{N(s,a)^{\tau}}{\sum_{b} N(s,b)^{\tau}}$$

Training Pipeline - Optimization

: 학습 데이터를 바탕으로 새로운 모델을 만드는 과정

- 64개의 GPU worker를 이용해 학습.
- 각 worker마다 32 batch-size 사용.
- 최근 생긴 500,000 게임에서 랜덤하게 골라서 배치를 구성.

$$l = (z - v)^2 - \pi^T \log p + c \|\theta\|^2$$

Training Pipeline - Optimization


| Thousands of steps | Reinforcement learning | Supervised learning |
|--------------------|------------------------|---------------------|
| 0–200 | 10^{-2} | 10^{-1} |
| 200-400 | 10^{-2} | 10^{-2} |
| 400-600 | 10^{-3} | 10^{-3} |
| 600-700 | 10^{-4} | 10^{-4} |
| 700-800 | 10^{-4} | 10^{-5} |
| >800 | 10^{-4} | - |


Learning rate used during reinforcement learning and supervised learning experiments, measured in thousands of steps (mini-batch updates).


Training Pipeline - Evaluation


: 새로운 모델을 평가하는 과정

- 좋은 퀄리티의 학습 데이터를 만들기 위해 새로운 모델이 나오면 평가함.
- \circ 현재의 가장 좋은 모델 α_{θ} 와 400판을 붙어 승률이 55%보다 높으면 모델 교체.









References

- Silver, D. et al. Mastering the game of Go with deep neural networks and tree search.
 (2016)
- Silver, D. et al. Mastering the game of Go without human knowledge (2017)
- He, K. Zhang, X., Ren, S. & Sun, J. Deep residual learning for image recognition (2016)
- Foster. AlphaGo Zero Explained In One Diagram. https://medium.com/applied-data-science/alphago-zero-explained-in-one-diagram-365f5abf67e0 (2017)

Thank You